

6.9. Реализация нейросетевых моделей

В рамках разработки были реализованы две ключевые нейросетевые модели: YOLOv5 для задач детекции объектов и LSTM с механизмом внимания для прогнозирования уровня риска на основе временных последовательностей событий. Как указано в разделе 4.4, данные модели обеспечивают автоматическое выявление объектов на

изображении и оценку уровня риска в охраняемых секторах, тем самым дополняя функциональность системы средствами предиктивной аналитики.

Создание и обучение нейросетевых модулей было выполнено на языке Python с использованием фреймворков TensorFlow и PyTorch, что обеспечило гибкость при построении архитектуры и настройке модели под задачу [22]. Для интеграции в основное приложение, написанное на C++/Qt6, модели были конвертированы в формат ONNX.

В системе реализованы два независимых модуля: модель пространственной детекции объектов на базе архитектуры YOLOv5 и модель временного анализа рисков, основанная на LSTM с механизмом внимания. Ниже представлено подробное описание их структуры, особенностей обучения и оценки качества.

1. Реализация модели YOLOv5

Модель YOLOv5 была разработана на основе официальной документации Ultralytics и реализована с нуля в соответствии с архитектурными принципами, изложенными в официальной документации [23]. Обучение модели проводилось на валидационном наборе данных COCO val2017, содержащем 5000 изображений с аннотациями для 80 категорий объектов [24].

Архитектура модели:

- Backbone: CSPDarknet53 — модифицированная версия Darknet, обеспечивающая эффективное извлечение признаков.
- Neck: Комбинация SPPF (Spatial Pyramid Pooling - Fast) и PANet (Path Aggregation Network) для агрегации признаков на разных масштабах.
- Head: YOLOv3 Head для генерации окончательных предсказаний.

Технические характеристики:

- Размер входного изображения: 640×640 пикселей.
- Количество параметров: около 7.5 млн.
- FLOPs: около 16.5 GFLOPs.
- Средняя точность (mAP@0.5): ~50.7% на COCO val2017.

Модель была обучена с использованием оптимизатора Adam, функции потерь BCEWithLogitsLoss для классификации и CIoU Loss для регрессии ограничивающих рамок. Для повышения обобщающей способности применялись техники аугментации данных, такие как мозаика, случайное масштабирование и повороты.

2. Реализация модели LSTM с механизмом внимания

Для прогнозирования уровня риска на основе временных последовательностей событий была разработана модель, основанная на архитектуре LSTM с интегрированным механизмом внимания. Модель обучалась на синтетически сгенерированной базе данных,

содержащей более 6000 событий с различными характеристиками. Структура модели, описывается большим количеством параметров, приведенных ниже.

Входной слой:

- Принимает последовательности длиной 10 временных шагов с 42 признаками на каждом шаге.

LSTM слои:

- Три последовательных LSTM слоя с 256, 128 и 64 нейронами соответственно.
- Каждый слой включает Dropout (0.3), Recurrent Dropout (0.3), L1/L2 регуляризацию и BatchNormalization.

Механизм внимания:

- Позволяет модели фокусироваться на наиболее значимых временных шагах, улучшая качество предсказаний.

Полносвязные слои:

- Два Dense слоя с 128 и 64 нейронами соответственно.
- Выходной слой с 3 нейронами, соответствующими уровням риска: низкий, средний и высокий.

После создания модели, была проведена подготовка данных.

Признаки:

- Временные (час, день недели, месяц в формате sin/cos), бинарные (выходной день, ночное время, пиковые часы), признаки активности (нормализованное количество событий), категориальные (one-hot кодирование типов событий, типов дронов, секторов патрулирования).

Предобработка:

- Нормализация числовых признаков с использованием RobustScaler.
- Балансировка классов с помощью техники SMOTE.

Параметры обучения:

- Оптимизатор: Adam с learning rate 0.001.
- Функция потерь: categorical_crossentropy.
- Размер батча: 32.
- Количество эпох: 50.
- Callbacks: EarlyStopping (patience=10), ReduceLROnPlateau, ModelCheckpoint, TensorBoard.

Результаты оценки модели:

- Accuracy: 88.72%.
- AUC: 0.9825.

- Precision: 98.13%.
- Recall: 82.32%.

Модель продемонстрировала высокую точность в классификации уровней риска, особенно для класса "высокий риск". Анализ графиков истории обучения и ROC-кривых, показал:

Функция потерь:

- Значение функции потерь на обучающей выборке стабильно снижается и достигает ~ 0.2 к 50-й эпохе.
- На валидационной выборке потери также постепенно уменьшаются, но с меньшей динамикой и без резких скачков — это признак устойчивого обучения.
- Разрыв между кривыми умеренный и не растёт критически, переобучение отсутствует или минимально.

Точность:

- Точность на обучающей выборке постепенно растёт и стабилизируется на уровне ~ 0.95 .
- Точность на валидации достигает ~ 0.70 уже к 2-й эпохе и остаётся стабильной, без резких провалов, что говорит о достижении плато и равновесия.

ROC-кривые:

- Все три ROC-кривые для классов 1, 2 и 3 демонстрируют высокую площадь под кривой ($AUC = 0.98$), что свидетельствует о высокой способности модели различать между классами.
- Кривые идут вдоль верхнего левого края графика, что говорит о низком уровне ложноположительных срабатываний при высокой полноте (True Positive Rate).
- Отсутствие “резких скачков” и стабильное поведение говорит о хорошем обобщении модели.

Визуализация истории обучения и ROC-кривых приведена на рисунках 6.9.1 и 6.9.2.




Рисунок 6.9.1 – Графики истории обучения (разработано автором)

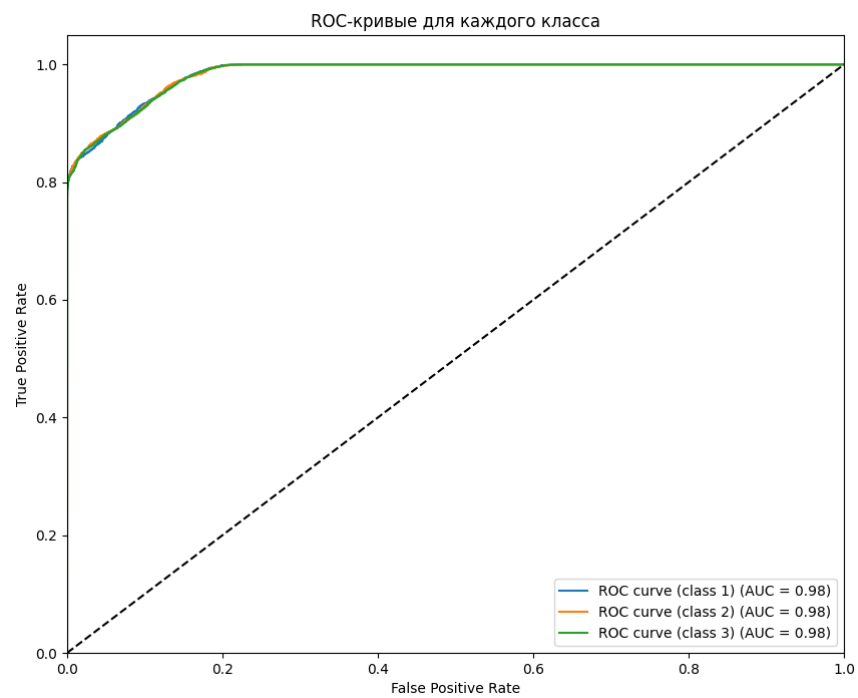


Рисунок 6.9.2 – График ROC-кривых(разработано автором)

